AI Native 實作題

DocuMind-AI：讓 AI 跟文件對話

本地 RAG 文件問答平台

架構與結果 ｜ 怎麼和 AI 一起做 ｜ 做完學到什麼

qwen3:32b ＋ bge-m3，本機 Ollama ・ 單次呼叫 ≤ 10,000 tokens ・ 每個回答附來源頁碼

本次報告

01 **題目與架構**
題目、系統架構

02 **運作流程**
入庫管線、問答管線

03 **困難解決**
表格、對話記憶

04 **文件規範問題**
超過 10K、 Summary 兩種做法

05 **實驗設計與結果**
檢索參數、 LLM 參數與模型、題庫、環境、結果

06 **與 AI 共同開發**
流程與證據、案例與心得

題目與架構 — 題目：三個限制、三個必答題、兩個說明題

不可違反的限制

1 LLM 只做 text-to-text

文件以本地程式庫 pypdf 解析，不把檔案或圖片交給任何 LLM 或雲端 API。模型是本機 Ollama 的 qwen3:32b 與 bge-m3。

題目限制 1

2 Context 上限 10,000 tokens

每次呼叫 prompt 加 completion 一律 ≤ 10,000；超量用檢索、壓縮、 map-reduce 處理，絕不截斷。

題目限制 2

3 不編造、附來源 ★

每個回答列出檔名、頁碼、片段；文件沒有的就明說，數字由程式再核對。

題目限制 3

三個必答題（文件： LightRAG, arXiv 2410.05779）

Q1	summary this document.
Q2	compare lightRAG with GraphRAG
Q3	Performance of ablated versions of LightRAG

兩個說明題

一	文件 token 超過 LLM context 怎麼處理？（第 7 頁）
二	Summary 怎麼處理？（第 8 頁）

交付

程式碼、簡報（架構與結果、如何與 AI 協作）、本機 Demo。

題目與架構 — 系統架構

設計要點

1 平台設計：從管理的物件出發

先定資料表與物件關聯，再寫後端與資料庫對接；設計前端頁面透過 API 與後端交互，最後設計 RAG 與 prompt 為 LLM 規範工作流與文獻搜查。

2 開發環境隔離與版控

開發於虛擬環境，工具裝在專案的 .venv，相依鎖定版本。
提交訊息照 Conventional Commits，階段打 tag，git 提交前跑完整檢查。

3 本機 Ollama，不用線上 API

文字不離開機器，同時節省開發測試成本。
10K token 的保證，靠 Ollama 的請求參數做硬限制。



運作流程　—　入庫管線：上傳到可提問

關鍵作法

1 PDF 文字擷取： pypdf

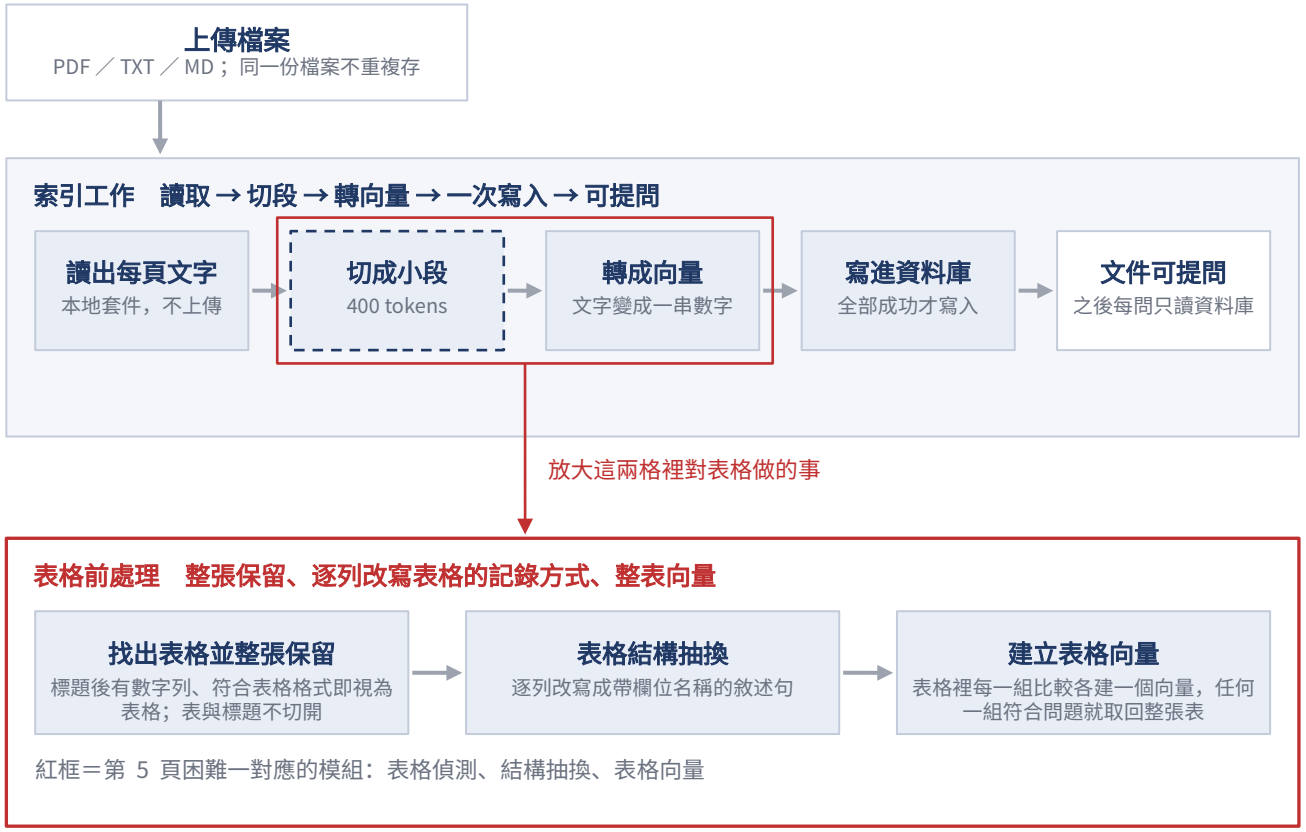
本地套件逐頁抽文字。切段不跨頁，每段記住頁碼，回答才標得出來源。

2 建立資料向量： bge-m3 ＋ pgvector

每段文字轉成向量存進資料庫。全部完成一次寫入資料庫。

3 表格特殊處理：數字題的答案都在表格

表格數據不特別處理的話，切段會把表切散。改為表格整張保留，並另外計算表格向量。



運作流程　—　問答管線：提問到回答

關 鍵 作 法

1 延續性意圖判斷

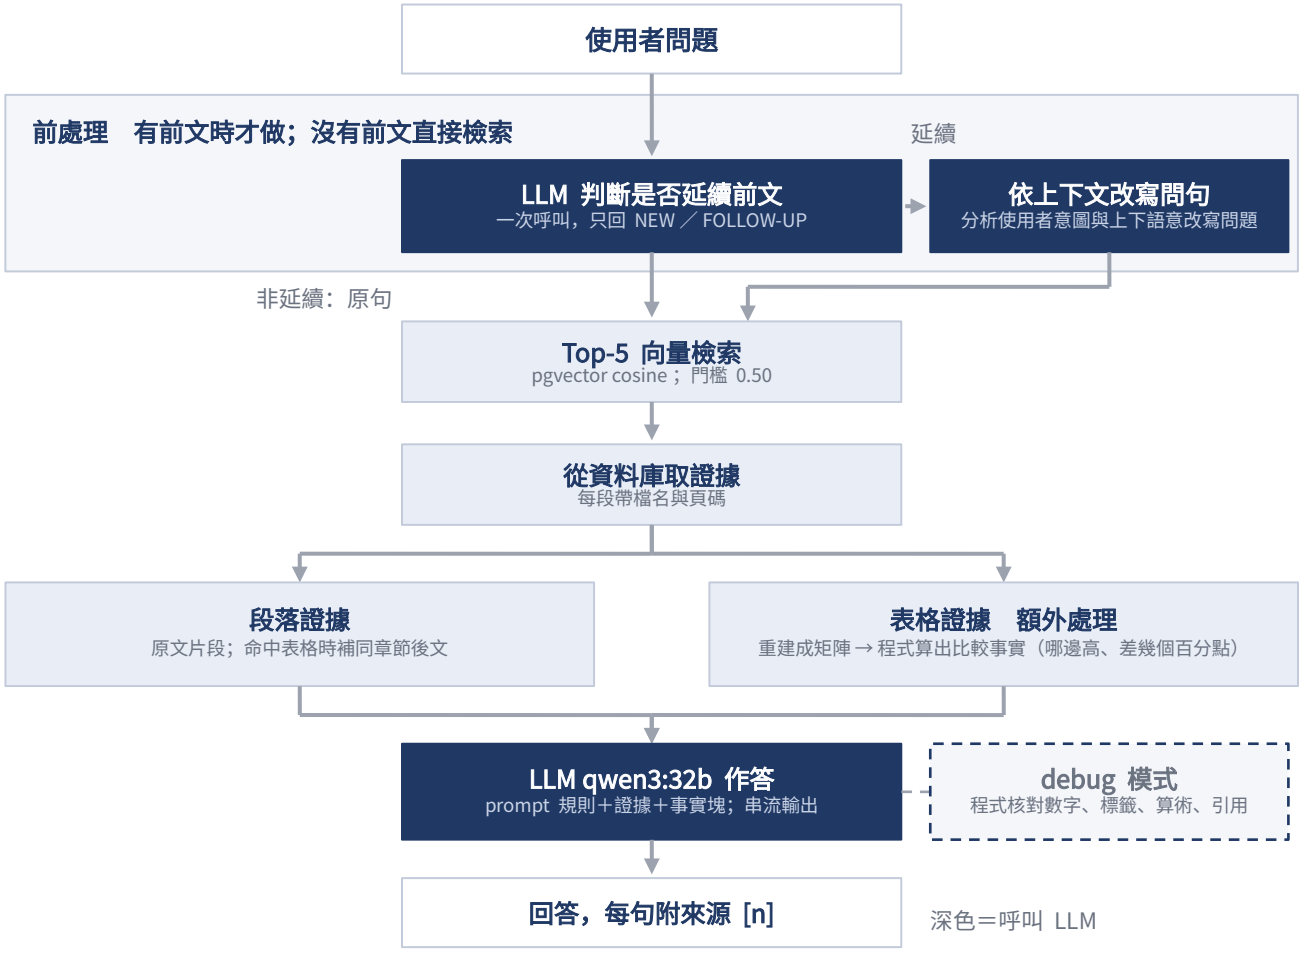
追問常用「他」「前一題的」，原句直接檢索找不到。有前文時先讓模型判斷是否有延續語意。

2 證據補充：段落與表格

取相似度最高的五段，每段帶檔名與頁碼；命中表格時同時補上表格後文的描述段落。程式先算好表格的比較資訊，再和段落一起交給模型。

3 LLM prompt 設計

分析方式：分析來源資料，並嚴格限制以來源資料做引用回答。
回答規則：比較題先發現、再數字、再例外；摘要題涵蓋問題、方法、實驗結果；文件沒提就明說；閒聊簡短回應。



困難解決 — 表格：切不對、讀不對、只對一篇對

① 切不對：表格被當一般段落切

ADR 0011

問題：表被切在列或數字中間，標題、表格描述、表被拆開

Table 1: Win rates …（標題被切到前一段）

片段 1　數字列 1–3

片段 2　數字列 4–6（切在 8,5|64 中間）

片段 3　數字列 7–9

改前：切在列或數字中間、標題分家、一塊四組比較的向量被平均

↓

Table 1 ＋標題　整張一塊

切點永遠不落在字或數字中間

改後：表格整張保留、切點避開數字；並為表格另外建立向量

結果　Q2（LightRAG 對 GraphRAG）要用 Table 1：原本排第 14、進不了前五；現在第 1

② 讀不對：模型讀不好數字格

問題：抽出的表只剩數字，模型抄得對、算不對

```
Agriculture CS Legal Mix
GraphRAG LightRAG GraphRAG LightRAG GraphRAG LightRAG GraphRAG LightRAG
Comprehensiveness 45.6% 54.4% 48.4% 51.6% 48.4% 51.6% 50.4% 49.6%
Diversity 22.8% 77.2% 40.8% 59.2% 26.4% 73.6% 36.0% 64.0%
```

改前：PDF 抽出來只有這樣，哪個數字屬於誰要靠位置對表頭；模型容易讀錯、算錯

↓

Comprehensiveness — Agriculture: GraphRAG 45.6%, LightRAG 54.4%; CS: GraphRAG 48.4%, LightRAG 51.6%; Legal: GraphRAG 48.4%, LightRAG 51.6%; Mix: GraphRAG 50.4%, LightRAG 49.6%

程式算好的事實塊

LightRAG 對 GraphRAG：16 項中 LightRAG 13 項較高；例外是 Mix 的 Comprehensiveness、Empowerment、Overall，各差 0.8、1.6、0.8 個百分點

改後：逐列改寫成帶欄位的敘事句子；比較與計數由程式先算好

結果　原本 Q2 寫 LightRAG 都是贏的，沒提 Mix 資料集的三個例外；Q3 整篇沒有數據
現在數據、計算與例外都列出且正確

③ 規則過擬合問題

問題：第一版只會轉換第一篇論文的表格；換第二篇論文，四張表一格都抽不出

改前：第二篇論文四張表一格都抽不出
規則寫死了一種表格樣式

→

解法：規則從行列維度下手
欄位配置由行列維度決定，再抽取數字對齊欄位名稱

→

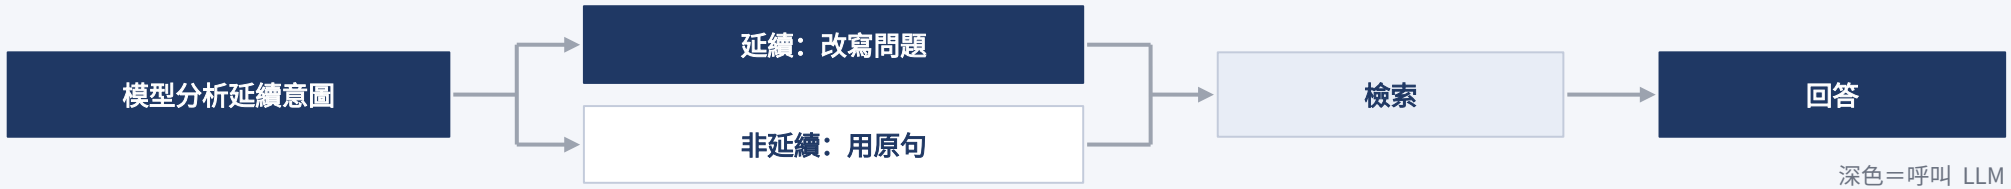
結果：兩篇論文六張表轉換成功
第三篇 RAPTOR 的表格樣式還不支援，尚未達到理想的泛化

困難解決 — 對話記憶：不補就斷掉，補了又多幻覺

每一輪「測了什麼 → 發現什麼問題 → 針對它的決策」； LLM 穩定性用 Try & Error 測試

	測了什麼	發現什麼問題	針對這個問題的決策
① 起點	發生延續性意圖時，例如「剛剛那個方法輸在哪」	延續性問題未處理時一樣拿去向量檢索，檢索不到而答非所問	多一級文字改寫，先把指稱換成實際對象再檢索
② 改寫（嘗試一）	模型判斷要改寫時把上下文加入過多	重點被稀釋，改寫規則不明確，問句變長、檢索走偏	重新設計 prompt：只補上指稱的對象（主詞、受詞、補語）
③ 補對話（嘗試二）	為了理解延續意圖，把歷史對話放進回答的 prompt	原本答對的題反而答錯：消融題把 -High 、 -Low 的定義寫反；對話太多讓模型失焦	對話紀錄只給判斷與改寫這兩步用，回答不帶對話
④ 修正	換更多不同的延續問題讓模型判斷，測泛化	判斷不穩， prompt 的限制與定義不夠明確	重新設計 prompt 並加入與論文無關的中性範例；判斷正確率約 45% → 90%

最終做法



深色＝呼叫 LLM

文件規範問題 — 文件 token 超過 LLM context 怎麼處理

透過限制讀取相關片段，避免文件 token 超過限制；送出前本地計數、送到 Ollama 再擋一次

關鍵作法

1 Chunking 文件切塊

例如每塊 400 tokens，建立 Embedding 並存入 pgvector。

2 Retrieval 向量檢索

透過 Top-K 的設計，提問時只找最相關的 Top-K 個 Chunk， K 值由實驗決定。

3 各階段的 token 分配

Qwen3 Tokenizer 計數，控制 Prompt ＋檢索證據＋ Output ≤ 10K。
模型請求參數限制，避免整體超過 10K context size。

Token 預算分配



＝ 10,000 tokens。最左兩小段：使用者問題 ≤ 200、系統規則（prompt 固定部分）約 500。

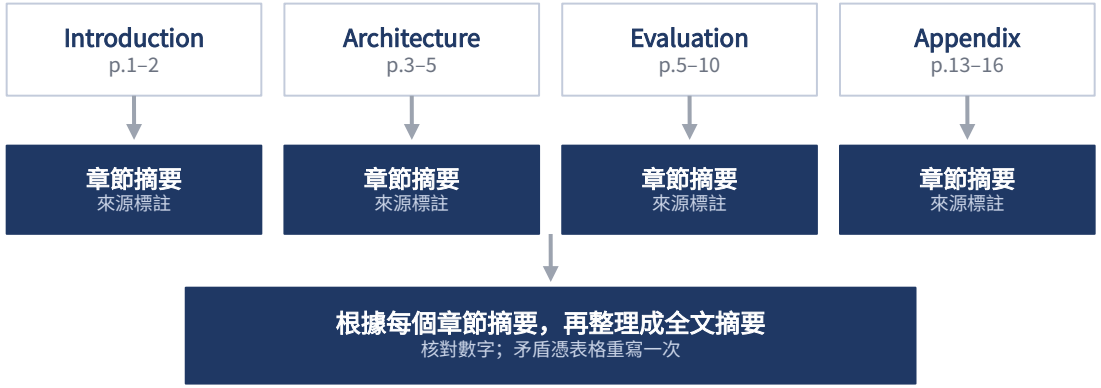
兩層守門



文件規範問題 — Summary 的兩種做法

方式一 摘要樹

LightRAG 共 8 個章節單位，圖示其中四個



依章節切單位，每單位一次呼叫（輸入 ≤ 6,000 、輸出 ≤ 1,500 ）→ 一次呼叫合成全文摘要

方式二 走一般檢索



走一般檢索：前 5 段約 2,000–2,500 tokens ，和一般問題同一條路

兩種做法的差距

摘要應涵蓋：研究問題、方法、實驗結果

	方式一 摘要樹	方式二 一般檢索
覆蓋	整篇；問題、方法、實驗結果都有，數據帶引用頁碼	約 13% ；問題與方法有寫，常缺實驗結果
代價／弱點	11 次呼叫、分鐘級等待；多層 LLM 摘要曾把章節數字串成不存在的範圍句	1 次呼叫、秒級等待；內容不夠詳細，看不到數據

實驗設計 — 檢索參數：切塊、 Top-K 、 Hybrid 、門檻

切塊 400 、 Top-K 5 、純向量、門檻 0.50 ； 每個參數都有數據， Hybrid 量過沒贏就不用

指標： Recall@K ＝一題需要的證據有幾成落在前 K 段

① 切塊 × Top-K ： 兩個參數一起看

純向量 Recall@K ； 括號是證據 tokens

切塊 ＼ K	3	5	8
256	0.76 （ 1,077 ）	0.81 （ 1,664 ）	0.83 （ 2,428 ）
400 （採用）	**0.83 （ 1,374 ）**	**0.88 （ 2,112 ）**	**0.91 （ 3,245 ）**
600	0.75 （ 1,661 ）	0.80 （ 2,747 ）	0.88 （ 4,226 ）

256 太碎（表與定義段被切散）、 600 每題多三成 tokens 。

切塊定 400 每個 K 下都是 400 最好（ 3 ： 0.83 ； 5 ： 0.88 ； 8 ： 0.91 ）。

K 定 5 400 下 K 由 5 到 8 只多 0.03 、證據 tokens 多 54% ，故取平衡選 5 。

② 相似度門檻：低於它就當文件沒提

最高相似度低於門檻，就當文件沒提（仍給最近三段，但告訴模型）；門檻要同時擋住 3 題無答案題、不誤擋 15 題有答案題

門檻	擋住無答案題	誤擋有答案題
0.45 （原值）	1–2 / 3	0 / 15
0.50 （採用）	**3 / 3**	**0 / 15**
0.55	3 / 3	切塊 600 時 2 / 15

0.50 是三種切塊都 3/3 且 0 誤擋的最低值，所以採用。

③ Hybrid ： 向量之外再加全文檢索（ RRF 合併）

設定（切塊 400 、 K 5 ）	Recall@5	證據 tokens
純向量（採用）	**0.88**	**2,112**
Hybrid	0.74	2,329

全文檢索整體比純向量低，不採用。

實驗設計 — LLM 參數與模型選擇

temperature 用穩定性實驗決定為 0；換模型正確性相同，預設維持 qwen3:32b （答案乾淨、較快）

temperature （Q2、Q3 各 10 次，每批重新入庫）

temperature	Q2 （10 次）	Q3 （10 次）	合計	十次回答
0 （採用）	**10 、 9**	**9 、 10**	**19/20 、 19/20**	**幾乎同一篇**
0.2	7	6	13/20	十次十種
0.4	8	5	13/20	十次十種

0 到 0.2 是明顯的坎： 0.2 以上 Q3 十次有二到三次把 -High 讀成「只用 high-level」； 0 的十次幾乎同一篇。預設 0，前端可調。

模型（同條件只換模型：三題各 10 次，溫度 0）

模型	大小	Q1／Q2／Q3 無錯誤資訊	十次是否相同	輸出 tokens （Q1／Q2／Q3）	每題秒數 （Q1／Q2／Q3）	特性
qwen3:32b （採用，預設）	**Q4_K_M， 20 GB**	**10／10／10**	**Q2、 Q3 逐字相同， Q1 只差引用標籤**	**441／489／1,014**	**20／26／50**	**答案精簡；沒提三格平手與三個版本的定義**
qwen3.6:27b （前端可選）	Q4_K_M， 17 GB	10／10／10	三題都逐字相同	530／643／1,857	24／33／84	內容較完整（平手、定義都有）；但消融題每次都把推理過程寫進答案（「Wait, the prompt says…」），輸出長近一倍、慢約 1.5 倍

正確性兩者相同；預設維持 qwen3:32b，因為答案乾淨、較快；另一個模型可在前端逐題切換。

實驗設計 — 測試題與資料集：三題之外還測了什麼

題目給的三題只測一篇論文的三種能力；再補細節、無答案、對話連續性、穩定性、其他論文與表格逐格

測試題與批次（每題附原文證據與頁碼；判定一律人工逐篇）

類別	為了測什麼	例子或做法
必答三題	**摘要、比較、消融表：一篇論文的三種能力**	**compare lightRAG with GraphRAG**
細節	內文事實，中英文問法各半	LightRAG 用哪四個評估面向？各是什麼意思？
無答案	文件沒有的不編造，明說沒提	如何在家烤麵包？
對話連續性	追問用「他」「前一題」這類指稱時，能否判出是延續、改寫正確、答案正確	同一對話底下測試十題，新問題與追問交錯
穩定性	同一題重複問會不會變；溫度要設多少	同一題重複十次 × 溫度 0 ／ 0.2 ／ 0.4
其他論文	同一套系統換一篇沒測過的論文還對不對	多測試 GraphRAG 、 RAPTOR 兩篇論文，各三題類比必答題
表格逐格	程式設計的表格改寫是不是只對特定 table 格式有效	兩篇論文六張表，驗證轉換結果

實驗設計 — 實驗環境：硬體、軟體、系統參數

一台機器、一張 GPU 跑完全部； Docker Compose 部署；所有參數集中在 .env，表裡的值就是 Demo 用的值

硬體、軟體與部署

項目	內容
GPU	NVIDIA A40 46 GB × 1 （生成模型 20 GB ）
CPU ／記憶體	32 核 Xeon； RAM 125 GB
作業系統	Ubuntu 24.04； Docker 29.5
模型服務	Ollama 0.24； qwen3:32b 20 GB； bge-m3 1.2 GB
後端	Python 3.12 、 FastAPI 0.162 、 SQLAlchemy； pypdf 6.21
資料庫	PostgreSQL 16 ＋ pgvector
前端	React ＋ Vite
部署	**Docker Compose 三個容器（前端、後端、 PostgreSQL ）＋主機 Ollama； make up 啟動**

時間感 16 頁論文入庫約 40 秒；一題回答 6 到 40 秒； make eval 重跑檢索實驗約 30 秒。

系統參數（.env；全部經 env_loader.py 讀取）

類別	參數	值
LLM	生成模型／嵌入模型	qwen3:32b ／ bge-m3
LLM	單次 context 上限	10,000 tokens
LLM	temperature ／思考模式	0 （前端可調）／關
RAG	切塊	400 tokens
RAG	Top-K	5
RAG	相似度門檻	0.50

實驗結果 — 三個必答題、泛化、對話連續性

預設系統三題十次全無錯誤資訊，差的是完整度；溫度一升就不穩；換論文與連續對話各有殘留，都列出來

三個必答題（temperature 0、不建摘要、同一對話；人工逐篇判定，有錯誤資訊才算不通過）

題	10 次成功率	還不夠的地方
Q1 摘要	10 / 10 無錯誤資訊	走檢索只看到約 13% 的論文：研究問題與方法都有寫，缺實驗結果與數字；要讀完整篇按「建立摘要」
Q2 比較	10 / 10	16 項中 13 項較高、Mix 的 3 項例外與差距都對；只比了勝率表，第 9–10 頁的成本（tokens、API 呼叫）與增量更新沒帶進來
Q3 消融	10 / 10	11 個關鍵數字、計數、例外全對；三格平手沒提（Legal 的 Diversity 86.4、Empowerment 83.6 對 -Low；Comprehensiveness 83.6 對 -Origin）；沒解釋 -High ／ -Low ／ -Origin 各拿掉什麼

溫度上升就不穩：0.2 時 Q2 7/10、Q3 6/10，0.4 時 8/10、5/10（修正前的系統量的，修正後只重跑溫度 0），所以預設 0。

泛化測試（同一對話、不建摘要、temperature 0）

測什麼	怎麼測	結果
不同論文	GraphRAG、RAPTOR 各三題	第一次 9/9；重跑 7/9（一題圖的數字格無標籤配錯、一題撞輸出上限）
表格泛化	兩篇論文六張表逐格對 LaTeX 原稿	全部相符（第二篇佔四張）

對話連續性（同一對話、不建摘要、temperature 0）

測什麼	怎麼測	結果
單一追問	三題後問「剛剛那個方法輸在哪幾個地方」	8 格與差距全對
十題混合	新問題與追問交錯，用「他」「前一題」指稱	判斷 9/9；答案 8/10（一題多列、一題數字推論錯）

與 AI 共同開發 — 怎麼和 AI 一起做

人定方向與驗收、AI 產出；每一步都有可檢查的產物

一個循環：每一步我和 AI 各做什麼、實際做了什麼

階段結束，回到下一份規格；淺色框＝這一步是什麼、為什麼、像是什麼

規格

我：定目標與驗收

AI：起草規格

每個階段的整體計畫遵循規則、系統設計原則與規格限制。

包含：

- 需求與驗收條件
- 系統架構
- API 與資料表
- 使用情境的設計

測試先行

我：審驗收是否寫成測試

AI：先寫預計達到的測試條件

測試目的：

AI 描述的「完成」不穩定，且容易判斷錯誤。

解決辦法：

先把預計完成的項目寫成自動測試，等程式寫完並通過這些測試才算開發完成。

實作

我：決定方向，請 AI 先查文獻

AI：寫程式、小步提交

實作方向：

1. 依測試條件完成，並迭代思考
2. 不熟悉的實作方向與架構先討論，請 AI 查文獻再決定
3. 寫程式的同時做 commit 紀錄與版本控制

驗證

我：設計實驗、實測抓錯

AI：跑檢查與實驗

實驗參數選擇：

設計驗證腳本，讓參數的選擇由數據證據堆疊出來。

驗證測試項目與劇本：

1. 判斷系統架構設計的完成率，有明確指標規範
2. 測試 LLM 回答品質是否符合劇本指標

Checkpoint

我：確認後才進下一階段

AI：整理紀錄、標版本

階段結束先全部檢查：

完成後更新紀錄、標版本，隨時能退回一個確定是好的狀態。

文件紀錄：

1. 與 AI 溝通的決策點紀錄
2. 遭遇的問題與解法，並標註時間

三條互動規則（寫在 CLAUDE.md）

① 依規格與計畫推進

每個階段先重新設計細節、向我說明並取得許可才動手；階段內小步 commit，階段結束 checkpoint 並打 tag。

② 改了模組先驗證再上線

前後端一改就跑完整檢查，部署後自動用腳本測 API（上傳、提問、追問、無答案題、10K 帳本），全過才可上線。

③ 測試劇本的固定流程

用題庫與測試腳本實測後，必須記錄回答與 token 用量，對照答案分析完成程度，並提出問題與修正方向，與我討論。

與 AI 共同開發 — 三個案例與心得

AI 的三個弱點，和我用來補的做法

三個案例：AI 的弱點 → 實際例子 → 我的對策 → 結果

AI 的弱點	實際例子	我的對策	結果
①AI 回報過度樂觀	測試條件訂得還不夠嚴謹的初期，測試結果常有問題，需經人工查核後才能修正。 實際案例： 1. 問答不準時，改提示詞之前我先想確認輸入的資料對不對。 AI 回報輸入正確，直到我要求把實際輸入逐字印出、由人核對，才發現表格文字對不上，而 AI 自己判別不出來 2. LLM 的答案裡有數值取錯，當下 AI 也沒發現，需人工判讀	1. 判定由人逐句對原文、標準答案先標好 2. 每次都記錄實際輸入與輸出 3. 每次發現問題都更新測試條件	1. 核對器重做並逐次調整後，誤報與漏報都降低 2. 留下的 log 也成為約束 AI 的紀錄
② 卡住時不主動試錯、也不查文獻，當下選一個做法就做	卡住時， AI 會自己判斷怎麼辦再與我討論，缺乏主動查文獻與試錯的思考。 實際案例： 1. 切塊大小、取幾段、溫度一開始都是直接給預設值 2. 表格數字一直讀錯格，只是反覆提出要改提示詞	參數用實驗決定；要它先查文獻再動手：〈1〉指出這是已知的「資料引用錯誤」、只加提示詞幾乎無效；〈2〉指出標籤要緊貼數字才保得住；參數則設計實驗反覆嘗試得出	1. 不再調提示詞，改由程式把標籤放到數字旁 → Q2 、 Q3 穩定答對 2. 參數由實驗表格選出表現最好的
③ 容易修成局部最佳解，缺少泛化與全局思考	AI 實作時容易形成區域最佳解，不會想到沒提到的資料上也要能用，缺乏全局觀。 實際案例： 1. 表格規則只認得測試論文的樣式，還想把那篇論文的定義寫進提示詞 2. 延續性意圖一開始用程式做關鍵字判斷	每次修正都換資料實測：多找其他論文、新舊問題混合，測試腳本執行多次確認穩定。 1. 確認沒影響其他功能 2. 驗證能泛化到其他資料	1. 第二篇論文從一格都讀不出到兩篇六張表都正確 2. 延續性意圖的判斷能泛化到其他問題

心得三句

AI 說成功仍需檢查，並不斷更新測試條件
卡住時參考文獻的做法，並實測找最佳解
多測其他資料，確保實作的「馬鞍」能泛化到其他資料上

〈1〉〈When LLMs Read Tables Carelessly〉（Yang 等，2026） 〈2〉〈Table Serialization Determines Which Relations Language Models Preserve〉（Ma 等，2026）

謝謝

DocuMind-AI： 讓 AI 跟文件對話

Demo　make up → http://127.0.0.1:3000 （區網 http://10.3.0.145:3000 ）。

附錄 A1 — 表格泛化：哪些表改寫成功、哪些不支援

判定標準：程式抽出的每一格（表、列、群組、欄、值）與 LaTeX 原稿逐格比對，全部相符才算成功；不在支援形狀內的表列為不支援

論文／表	形狀	逐格對 LaTeX 原稿	判定
LightRAG Table 1	兩層欄頭、每群 2 子欄、多區塊	全部相符	✓
LightRAG Table 2	兩層欄頭、每群 2 子欄、多區塊	全部相符	✓
LightRAG Table 4	單層欄頭、首欄名在表頭	形狀支援、可抽出；不在逐格比對清單	✓（未逐格）
GraphRAG Table 2	兩層欄頭、群組名兩個字、每群 5 子欄	全部相符	✓
GraphRAG Table 3	跨欄總標題＋兩個字的欄名	全部相符	✓
GraphRAG Table 4	6 欄、數值列標籤（0.5…）、分段列	全部相符	✓
GraphRAG Table 6	成對比較：兩個列標籤欄、每群 4 子欄、 <0.001	全部相符； Mean 1 對 Mean 2 不算一對，所以沒有方向與例外事實	✓
RAPTOR 各表	Model 列＋四個指標欄，不在五種形狀內	未改寫；回答的數字來自內文段落	✗ 不支援
GraphRAG Figure 2 勝率方格	圖；抽出只剩數字格、沒有列欄標籤	消融題把格子配錯邊（重跑時出錯）	✗
合併儲存格、三層以上欄頭、多層列名、跨頁表、沒有「Table N」標題的表、圖片表	—	未驗證	✗ 不支援

泛化指上面五種表格形狀（兩層欄頭、單層欄頭、跨欄總標題、數值列標籤、成對比較），不是任意表格。

附錄 A2 — 三個必答題的穩定性：四種溫度各 10 次

判定標準：人工逐篇讀，有一句錯誤資訊（數字、標籤、方向、定義）就算不通過；第一張表是修正前、建摘要樹的系統，第二張是修正後、不建摘要的系統

修正前（建摘要樹、各自新對話）

temperature	Q1 摘要	Q2 比較	Q3 消融	合計	判定	不通過的內容
0（第一批）	10/10	10/10	9/10	29/30	✓	Q3 一次把 -High ／ -Low 的定義寫反
0（第二批，重新入庫）	10/10	9/10	10/10	29/30	✓	Q2 一次把「對 NaiveRAG」的數字拿去對 GraphRAG（配對錯）
0.2	10/10	7/10	6/10	23/30	✗	定義反向 3、配對錯 1、資料集標籤錯 2、數字錯 1
0.4	9/10	8/10	5/10	22/30	✗	定義反向 2、標籤錯 2、計數反向 1、數字錯 1、自相矛盾 1、輸出用盡 1

修正後（不建摘要、同一對話依序問三題、temperature 0）

批次	結果	判定	說明
三題，十次	30/30	✓	十次同一篇，與已判過的那組一字不差
三題，五個對話	15/15	✓	Q2、Q3 五次逐字相同；Q1 第一次多三個引用標籤、文字相同
三題，十個對話	30/30	✓	Q2、Q3 十次逐字相同，也與五個對話那組相同；Q1 九次無引用標籤、一次有，文字相同
GraphRAG 四題各五次，溫度 0 與 0.4	20/20	✓	數字全對；0.4 時一次把 77.76 寫成「77–78%」，標為無法核對

附錄 A3　—　檢索參數：切塊 × K 全表、相似度門檻全表

判定標準： Recall@K ＝一題需要的證據有幾成落在前 K 段；命中率＝至少找到一段證據的題目比例；門檻要擋住 3 題無答案題且不誤擋 15 題有答案題

切塊 × K（19 題題庫；Hybrid ✗ 未採用）

切塊	K	純向量 Recall	命中率	Hybrid Recall	命中率	證據 tokens	
256	3	0.76	0.87	0.53	0.60	1,077	
256	5	0.81	0.87	0.67	0.73	1,664	
256	8	0.83	0.87	0.78	0.87	2,428	
400	3	0.83	1.00	0.52	0.67	1,374	
400	**5**	**0.88**	**1.00**	**0.74**	**0.87**	**2,112**	**✓ 採用**
400	8	0.91	1.00	0.84	0.93	3,245	
600	3	0.75	0.87	0.71	0.80	1,661	
600	5	0.80	0.87	0.78	0.87	2,747	
600	8	0.88	0.93	0.86	0.93	4,226	

每格「正確拒答／誤拒答」。400 下 K 由 5 到 8 多的 0.03 是一段定義段，正式程式的表格後文已補到，所以 K 留 5。

相似度門檻（擋住無答案題／誤擋有答案題）

門檻	切塊 256	切塊 400	切塊 600	
0.30	0/3 ｜ 0/15	0/3 ｜ 0/15	0/3 ｜ 0/15	
0.35	0/3 ｜ 0/15	0/3 ｜ 0/15	1/3 ｜ 0/15	
0.40	1/3 ｜ 0/15	1/3 ｜ 0/15	1/3 ｜ 0/15	
0.45 （原值）	1/3 ｜ 0/15	2/3 ｜ 0/15	2/3 ｜ 0/15	✗ 擋不住
0.50	**3/3 ｜ 0/15**	**3/3 ｜ 0/15**	**3/3 ｜ 0/15**	**✓ 採用**
0.55	3/3 ｜ 0/15	3/3 ｜ 0/15	3/3 ｜ 2/15	✗ 600 誤擋
0.60	3/3 ｜ 3/15	3/3 ｜ 2/15	3/3 ｜ 3/15	✗ 誤擋

附錄 A4 — 對話連續性：同一對話十題，新問題與追問交錯

判定標準：「判斷」看模型判新問題或延續是否正確；「回答」人工逐篇讀，有錯誤資訊才算 ✗。條件： temperature 0 、不建摘要、對話脈絡關

#	問題	判斷	回答	說明
1	compare lightRAG with GraphRAG	— （無前文不判）	✓	16 項中 13 項、代表數字、 3 項例外都對
2	他在哪個資料集輸?	延續✓	✓	改寫成「 LightRAG 落後於 GraphRAG 的資料集」； Mix 三項與數字對
3	前一題提到的例外，各差幾個百分點?	延續✓	✗	改寫把原句吐回、低於門檻、沿用上一輪來源；前三行對，接著多列六組不該互比的配對（數字本身對）
4	Performance of ablated versions of LightRAG	新問題✓	✓	與單獨問時同一篇
5	剛剛那張表裡 -Origin 贏了哪幾格?	延續✓	✓	-Origin 優於 LightRAG 的四格與數字對
6	LightRAG 在 Legal 資料集的檢索用了多少 tokens？ GraphRAG 呢?	新問題✓	✓	<100 對 610,000； 1,399 社群、 610 個二級社群
7	那它們各需要幾次 API 呼叫?	延續✓	✗	LightRAG 1 次對； GraphRAG 把 610 個社群寫成「 610 次」，原文寫 hundreds
8	What datasets does the paper evaluate on?	新問題✓	✓	四個資料集
9	每個有幾份文件?	延續✓	✓	12 ／ 10 ／ 94 ／ 61； 語言跟使用者原句
10	and their token counts?	延續✓	✓	四個 token 數全對

合計：判斷 9/9；回答 8/10 無錯誤資訊。兩個殘留都在第 6 頁與第 13 頁交代。

附錄 A5 — 其他論文： GraphRAG 、 RAPTOR 各三題類比必答題

判定標準：人工對原文逐句讀，有錯誤資訊才算 ✗。條件：同一對話依序問三題、不建摘要、 temperature 0 ； 第一次與重跑是同一組問題兩次

論文	題	第一次	重跑	說明
GraphRAG	summary this document.	✓	✓	沒有數字；六個條件、兩個資料集、風險聲明都對
GraphRAG	compare GraphRAG with vector RAG	✓	✓	勝率範圍 Podcast 72–83% ／ 75–82% 、 News 72–80% ／ 62–71% 與原文一致；表格沒被檢索到，數字來自內文
GraphRAG	Performance of the different GraphRAG conditions (C0–C3) compared with TS and SS	✓	✗	重跑時 Figure 2 的勝率方格抽出只剩數字、沒有列欄標籤，模型把格子配錯邊（ C0 對 TS 59% 應為 TS 對 C0 ）； 定性部分對
RAPTOR	summary this document.	✓	✓	QuALITY +20% 、消融 56.6% 對 55.8% 、幻覺 4% 、壓縮率 72% 、摘要 131 tokens 全對
RAPTOR	compare RAPTOR with BM25 and DPR	✓	✗	重跑時撞 2,500 tokens 輸出上限、狀態中斷；數字都對，但主詞寫成「 RAPTOR with RAPTOR 」。表格排版不在支援形狀內，數字來自內文
RAPTOR	Performance of the different retrieval strategies (tree traversal vs collapsed tree)	✓	✓	collapsed tree 較好、 2000 tokens ≈ top-20 、 UnifiedQA 400 tokens 、 20 篇 QASPER

合計：第一次 9/9 （含 LightRAG 三題）； 重跑 7/9 。兩篇新論文的表格都沒進事實塊，數字全靠模型從內文抄，這是兩個重跑錯誤的共同背景。

附錄 A6 — Summary 兩種做法

判定標準：五項內容（研究問題／提出什麼方法／方法怎麼運作／方法的其他優點／實驗結果）有沒有寫到；有錯誤資訊就 ✗。消融三組溫度 0.5 、各一次

變體	問法	路線	呼叫／ prompt	五項內容	錯誤資訊	判定
B1 檢索	Describe what this paper proposes, how it works, and what the experiments found.	一般檢索（ 5 段）	1 次／ 2,245	有提出什麼方法、實驗結果（無數字）；缺研究問題、方法怎麼運作、方法的其他優點	說「論文沒有具體數字」，其實有 Table 1	✗
B2 檢索	這份文件提出了什麼方法、做了什麼實驗、結果如何?	一般檢索（ 5 段）	1 次／ 2,427	有研究問題、提出什麼方法、方法怎麼運作、實驗結果（無數字）；缺方法的其他優點	無；評估面向寫得籠統	✓ 不完整
B3 摘要樹	summary this document.	摘要樹（全文＋ 8 份章節摘要）	1 次／ 3,520 （入庫另 11 次）	五項都有、含數字	「 67.6% 到 86.4% 」範圍不準，核對器標出	✓ 一處標註
按鍵建樹（修正後）	**summary this document.**	**對話中按「建立摘要」後走摘要路線**	**建樹 156 秒；回答 3,384 ＋ 409**	**五項都有、含數字**	**一處偏強：混合模型在全面性優於僅低層**	**✓**
走檢索（修正後， temperature 0 ，五次）	summary this document.	一般檢索（ 5 段）	1 次／約 2,400	四項有寫；缺實驗結果與數字	無	✓ 不完整

Demo 預設走檢索（零預付、答得短）；要讀完整篇按「建立摘要」。兩種路線每次呼叫都 ≤ 10,000 tokens 。